

İnce Kesit Görüntülerinde Karbonat Mikrofasiye Bileşenlerinin Derin Öğrenme Tabanlı Segmentasyonu

Deep Learning-Based Segmentation of Carbonate Microfacies Components in Thin-Section Images

Musawer Muradi ¹, Alev Mutlu ², Arnaud Gallois ³

¹ Bilgisayar Mühendisliği, Kocaeli Üniversitesi, Kocaeli, 41380, Türkiye

² Bilgisayar Mühendisliği, Kocaeli Üniversitesi, Kocaeli, 41380, Türkiye

³ Jeoloji Mühendisliği, Kocaeli Üniversitesi, Kocaeli, 41001, Türkiye

Article Info	Özet
Research paper	Karbonat kayaçların ince kesit görüntülerinde mikrofasiye bileşenlerinin tanımlanması, hem çevresel yorumlar hem de rezervuar karakterizasyonu için kritik öneme sahiptir. Ancak bu analizler çoğunlukla uzman jeologların görsel değerlendirmelerine dayanmakta, bu da süreci zaman alıcı, yoruma açık ve tekrarlanabilirlik açısından sorunlu hale getirmektedir. Bu çalışmada, karbonat ince kesitlerinde 7 mikrofasiye sınıfını içeren ve 18 görüntüden oluşan küçük, yüksek oranda dengesiz bir veri seti üzerinde makine öğrenimi tabanlı bir segmentasyon ve sınıflandırma yaklaşımı geliştirilmiştir. Segmentasyon aşamasında Segment Anything Model (SAM) kullanılmış, sınıflandırma aşamasında ise özellik (feature) mühendisliği ve XGBoost modelleri incelenmiştir. Aşırı sınıf dengesizliği nedeniyle birçok geleneksel yaklaşım başarısız olmuş, nihai çözüm odaklı kayıp fonksiyonu (focal loss) uygulanarak artırılmış bir performans elde edilmiştir. Çalışmanın temel katkısı, sınırlı ve dengesiz bilimsel veri kümelerinde model başarısını optimize etmeye yönelik bir makine öğrenimi yaşam döngüsü sunmaktır.
Anahtar Kelimeler	
Karbonat mikrofasiye İnce kesit analizi Makine öğrenimi Segmentasyon Sınıf dengesizliği Öznetelik mühendisliği	
Article Info	Abstract
Research paper	The identification of microfacies components in carbonate thin-section images is critically important for both environmental interpretation and reservoir characterization. However, these analyses rely heavily on the visual assessments of expert geologists, making the process time-consuming, subjective, and difficult to reproduce. In this study, a machine learning-based segmentation and classification approach was developed for a small and highly imbalanced dataset consisting of 18 images and seven microfacies classes. The segmentation stage employed the Segment Anything Model (SAM), while feature engineering and XGBoost-based methods were examined in the classification stage. Due to the extreme class imbalance, many conventional approaches failed, and improved performance was achieved by applying a focal loss objective function. The main contribution of this work is the presentation of a machine learning lifecycle designed to optimize model performance in limited and imbalanced scientific datasets.
Keywords	
Carbonate microfacies Thin-section analysis Machine learning Segmentation Class imbalance Feature engineering	

1. Giriş

Karbonat kayaçlar, sedimanter havzaların gelişim

dinamiklerini anlamada, paleoekolojik yorumlamalarda ve özellikle hidrokarbon ile yeraltı suyu rezervuarlarını n karakterizasyonunda temel bir role sahiptir [1] [2].

Bu kayaçların gözeneklilik ve geçirgenlik gibi rezervuar özellikleri, büyük ölçüde mikrofasiye bileşenlerinin türü, dağılımı ve dokusal özellikleri tarafından belirlenir [3]. Dolayısıyla karbonat mikrofasiye analizleri, hem akademik araştırmalarda hem de endüstriyel uygulamalar da kritik bir değerlendirme adımdır [4].

Karbonat kayaçların incelenmesinde en yaygın ve güvenilir yöntem, 30 µm kalınlığında hazırlanan ince kesitlerin polarizan mikroskop altında analiz edilmesidir [4]. İnce kesit petrolojisi, tanelerin şekil, boyut, doku ve mineralojik bileşimini ayrıntılı bir şekilde ortaya koyarak çökeltme ortamı, diyajenez ve stratigrafik süreçler hakkında kapsamlı bilgi sağlar [4]. Ancak bu yöntem yüksek derecede uzmanlık gerektirir; yorumlayıcıdır, zaman alıcıdır ve farklı uzmanlar arasında önemli ölçüde tutarsızlık gözlenebilir [5]. Bu nedenle, ince kesit görüntülerinin otomatik işlenmesi ve sınıflandırılması hem hız hem de tekrarlanabilirlik açısından önemli bir potansiyel sunmaktadır.

Bilgisayarlı görü ve makine öğrenimi teknolojilerinin gelişmesiyle, ince kesit görüntülerinin otomatik analizi mümkün hale gelmiştir [6] [7]. Ne var ki jeolojik görüntüler, tipik bilgisayarlı görü veri kümelerine kıyasla belirgin zorluklar içermektedir. Karbonat mikrofasiye bileşenleri, şekil ve doku bakımından yüksek varyasyon gösterir; görüntüler sınırlı sayıdadır; sınıf dağılımı sön derece dengesizdir; bazı bileşenler yalnızca birkaç örnek ile temsil edilir [8] [9]. Bu özellikler, özellikle derin öğrenme modellerinin dengeli ve büyük miktarda veri gerektiren yapısıyla çelişmekte ve geleneksel yaklaşımların doğrudan uygulanabilirliğini azaltmaktadır [8] [9].

Bu çalışma, küçük ve yüksek derecede dengesiz ince kesit veri setlerinde güvenilir bir sınıflandırma sistemi tasarlamayı amaçlamaktadır. Bu kapsamda Segment Anything Model (SAM) kullanılarak tane bazlı segmentasyon yapılmış, ardından detaylı bir öznitelik mühendisliği süreciyle her bir tane çok boyutlu bir öznitelik vektörüne dönüştürülmüştür. Farklı makine öğrenimi yöntemleri test edilmiş ve nihayetinde sınıf dengesizliğiyle başa çıkabilen focal loss tabanlı bir XGBoost modeli en başarılı yaklaşım olarak belirlenmiştir.

Bu makalenin temel katkısı, karbonat mikrofasiye bileşenlerinin otomatik tanımlanmasına yönelik belirli bir model önermekten ziyade, sınırlı ve dengesiz bilimsel veri kümelerinde etkili performans sağlayan bütüncül bir makine öğrenimi yaşam döngüsü ortaya koymaktır. Çalışma, hem jeolojik görüntü analizi alanına hem de küçük ölçekli veri kümelerinde sınıf dengesizliğiyle mücadeleyle yönelik metodolojik içgörüler sunmaktadır.

2. Malzeme ve Yöntem

2.1. Veri Seti

Çalışmada kullanılan veri seti toplam 18 ince kesit görüntüsünden oluşmakta olup bu görüntülerde 2.687 adet tane manuel olarak segmentlenmiştir. Veri setinde yedi farklı mikrofasiye sınıfı bulunmaktadır: peloid, ooid, intraclast, broken ooid, ostracod, quartz grain ve bivalve. En belirgin veri özelliği sınıflar arasındaki aşırı dengesizliktir; peloid sınıfı örneklerin yaklaşık %85,6'sını oluştururken bazı sınıflar yalnızca birkaç örnek içermektedir. Bu durum, model performansını en fazla etkileyen yapısal sınırlama olarak değerlendirilmiştir. Ayrıca görüntülerin sayıca az olması ve her görüntüdeki tane sayılarının büyük değişkenlik göstermesi, veri setinin bağımsız alt gruplara ayrılmasını zorlaştırmış ve veri bölme stratejilerini doğrudan etkilemiştir.

Class	Count	Percentage	Images_Present	Total_Images	Images_coverage_perc
Bivalve	4	0.15	2	18	11.1
Broken Ooid	29	1.08	12	18	66.7
Intraclast	103	3.83	11	18	61.1
Ooid	210	7.82	16	18	88.9
Ostracod	32	1.19	3	18	16.7
Peloid	2300	85.6	18	18	100
Quartz Grain	9	0.33	1	18	5.6

Tablo 1. Veri seti dağılım tablosu

2.2. Görev Tanımı

Bu çalışma iki aşamalı bir makine öğrenimi süreci olarak tasarlanmıştır. İlk aşamada, ince kesit görüntülerindeki tanelerin sınırlarının belirlenmesi ve bağımsız nesne birimlerine dönüştürülmesi amaçlanmıştır. Böylece bütün görüntü üzerinden bir sınıflandırma yerine tane düzeyinde karar verilebilmiştir. İkinci aşamada ise segmentasyonla elde edilen her bir tane, ait olduğu mikrofasiye sınıfına göre sınıflandırılmıştır. Böyle bir yapı hem jeolojik yorumlama süreçlerine daha uyumludur hem de görüntü içeri çeşitliliği doğrudan modelin eğitimi ne yansıtılmaktadır.

2.3. Segmentasyon Yaklaşımı


Segmentasyon için Segment Anything Model (SAM) kullanılmıştır. SAM, jeolojik görüntüler üzerinde doğrudan eğitilmiş olmamasına rağmen farklı görüntü türlerinde yüksek doğrulukla maske üretebilmesi, hızlı ve tutarlı çalışması nedeniyle tercih edilmiştir. SAM tarafından üretilen maskeler daha sonra sınıflandırma aşamasına girecek tane birimlerini oluşturmuştur [10]. Segmentasyon kalitesinin sınıflandırma performansını doğrudan etkilediği göz önünde bulundurularak maske sonuçları manuel olarak incelenmiş ve hatalı segmentler işlen

meden önce ayıklanmıştır.

2.4. Özellik Çıkarma

Segmentasyon sonucunda elde edilen her bir tane için çeşitli geometrik, dokusal ve renk tabanlı öznitelikler çıkarılmıştır. Geometrik öznitelikler tane alanı, çevresi, şekil oranları ve eksantriklik gibi morfolojik ölçümleri kapsamaktadır. Dokusal öznitelikler Local Binary Patterns (LBP) ve Gray Level Co-Occurrence Matrix

(GLCM) üzerinden hesaplanmış, böylece yüzey dokusu na ilişkin istatistiksel özelliklerin modele taşınması sağlanmıştır [11] [12]. Renk özellikleri RGB kanal istatistikleri üzerinden elde edilmiş, ek olarak tane sınırlarının karmaşıklığı gibi jeolojik açıdan anlamlı özel metrikler de türetilmiştir. Toplamda her tane için yaklaşık 65 öznitelik çıkarılmıştır ve bu öznitelikler sınıflandırma algoritmalarına giriş verisi olarak kullanılmıştır.



Şekil 1. Özellik Önem Tablosu

2.5. Değerlendirilen Modeller

Çalışmada çok sayıda makine öğrenimi yöntemi incelenmiştir. Random Forest, Logistic Regression ve standart XGBoost gibi yöntemler başlangıç noktası olarak test edilmiş ancak veri dengesizliği nedeniyle azınlık sınıflarında başarısız sonuçlar vermiştir. CNN tabanlı özellik çıkarımı, ImageNet üzerinde eğitilmiş derin modellerin karbonat mikrofasiye morfolojileriyle yeterli ilişkilenebilmesi nedeniyle beklenen performansı göstermemiştir. SMOTE gibi veri artırma yöntemleri ise sentetik örneklerin jeolojik gerçekliği bozması nedeniyle uygun bulunmamıştır [13]. Ayrıca binary cascade gibi sınıf ayrıştırmaya yönelik doğrusal stratejiler, zincirleme hatalara yol açmış ve genel başarıyı düşürmüştür. Tüm


bu denemelerin ardından focal loss kullanılarak modifiye edilen XGBoost modeli, özellikle azınlık sınıflarına daha iyi odaklanabilmesi nedeniyle en başarılı yaklaşım olarak seçilmiştir [14].

2.6. Nihai Model

Nihai model, SAM ile segmentasyon ve focal loss tabanlı XGBoost ile sınıflandırma aşamalarından oluşan iki aşamalı bir yapıdadır. Focal loss, klasik kayıp fonksiyonlarının çoğunluk sınıflarındaki baskın etkisini azaltarak modele nadir örnekleri öğrenme kapasitesi kazandırmıştır [15] [16]. Böylece hem dengeli doğruluk hem de azınlık sınıflarının tahmin performansında belirgin iyileşme elde edilmiştir. Sistem, küçük ölçekteki jeolojik veri kümelerinde uygulanabilecek esnek ve genel bir çerçeve sunmaktadır.

FaciesNet: Complete System Architecture

Two-Stage Pipeline: Segmentation → Classification



Şekil 2. Önerilen model

3. Bulgular ve Tartışma

Bu çalışma, küçük ve yapısal olarak dengesiz bir jeolojik veri seti üzerinde etkili bir makine öğrenimi yaklaşımı geliştirmeyi hedeflemiştir. Çalışmanın en büyük katkısı, farklı modeller veya hiperparametreler denemekten ziyade, veri dengesizliğinin sistem düzeyinde çözülmesine odaklanan bir makine öğrenimi yaşam döngüsü ortaya koymasındır.

Çalışmanın gösterdiği başlıca bulgular:

- Dengesizlik, model mimarisinden daha baskın bir faktördür.
- Jeolojiye özgü öznitelikler, derin öğrenme tabanlı özniteliklerden daha iyi performans göstermiştir.
- Focal loss, dengesiz veri kümeleri için en tutarlı iyileştirmeyi sağlamıştır.
- Başarılı bir sistem performansı, segmentasyon kalitesine yüksek derecede bağlıdır [17].
- Veri bölme stratejisi, özellikle küçük veri setlerinde model başarısını dramatik biçimde etkiler [17].

4. Sonuçlar

Bu çalışma, ince kesit karbonat görüntülerindeki mikrofasiye bileşenlerini sınıflandırmak için makine öğrenimi tabanlı bir çözüm önermiştir. Sonuçlar, derin öğrenme model karmaşıklığından çok uygun yaşam döngüsü tasarımının, dengesizlikle mücadele yöntemlerinin ve alan bilgisiyle

beslenen öznitelik mühendisliğinin başarının ana anahtarı olduğunu göstermektedir.

Bu çerçeve, diğer küçük ve dengesiz bilimsel veri setlerine de uyarlanabilir niteliktedir.

Etik Standartlar Beyanı

Bu makalenin yazarları, bu çalışmada kullanılan materyal ve yöntemlerin etik kurul izni ve / veya yasal-özel izin gerektirmediğini beyan etmektedir.

Çıkar Çatışması

Yazarlar, bu makalede bildirilen çalışmayı etkilemiş gibi görünebilecek, bilinen rakip mali çıkarları veya kişisel ilişkileri olmadığını beyan ederler.

Yazar Katkı Beyanı

Yazar 1: Metodoloji (Fikrin oluşması), tasarımın yapılması, makalenin kontrol edilmesi

Yazar 2: Metodoloji (Fikrin oluşması), tasarımın yapılması, makalenin kontrol edilmesi

Yazar 3: Veri düzenlemesi, elde edilen sonuçların değerlendirilmesi, makalenin kontrol edilmesi

Kaynaklar

- [1] M. E. Tucker, *Sedimentary Petrology: An Introduction to the Origin of Sedimentary Rocks*, Wiley-Blackwell, 2001.
- [2] J. L. Wilson, "Carbonate Facies in Geologic History," *Springer*, 1975.
- [3] F. J. Lucia, "Carbonate Reservoir Characterization," *Springer*, 1999.
- [4] E. Flügel, "Microfacies of Carbonate Rocks: Analysis, Interpretation and Application," *Springer*, 2010.
- [5] D. I. S. & M. P. Waltham, "Observer variability in petrographic image analysis," *Sedimentary Geology*, no. 401, pp. 105-112, 2020.
- [6] Y. B. Y. & H. G. LeCun, "Deep learning," *Nature*, vol. 7553, no. 521, p. 436-444, 2015.
- [7] I. B. Y. & C. A. Goodfellow, *Deep Learning*, MIT Press, 2016.
- [8] Z. C. W. & C. H. Zhao, "Applications of deep learning to geological image analysis," *Computers & Geosciences*, no. 118, pp. 1-11, 2018.
- [9] T. & V. E. Szabo, "Challenges in automated petrographic image analysis: A review," *Earth-Science Reviews*, no. 220, p. 103729, 2021.
- [10] A. Kirillov, E. Mintun, N. Ravi and et. al., "Segment Anything," *arXiv:2304.02643*, 2023.
- [11] T. P. M. & M. T. Ojala, "Multiresolution gray-scale and rotation invariant texture classification with local binary patterns," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 971-987, 2002.
- [12] R. M. S. K. & D. I. Haralick, "Textural features for image classification," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 6, pp. 610-621, 1973.
- [13] N. V. B. K. W. H. L. O. & K. W. P. Chawla, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, no. 16, pp. 321-357, 2002.
- [14] T. & G. C. Chen, "XGBoost: A scalable tree boosting system," *KDD '16*, pp. 785-794, 2016.
- [15] T.-Y. G. P. G. R. H. K. & D. P. Lin, "Focal loss for dense object detection," *Proceedings of ICCV*, pp. 2980-2988, 2017.
- [16] H. & G. E. A. He, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 9, no. 21, pp. 1263-1284, 2009.
- [17] F. S. A. & D. P. Sultana, "Advancements in image segmentation using deep learning: A survey," *IEEE Access*, no. 9, pp. 9535-9556, 2020.